学习情境 L01：当取数要排队两天—Data Agent 破局（6 学时）

一、学习情境基本信息

学习领域	LF	讲次	学时	布鲁姆主层级	双元场地
LF1 数据中台认知与数仓架构规划	LF1（第 1/3 讲）	L01	6（校内 4 + 企业站 2）	记忆 / 理解（记/解），应用渗透	校内理实一体教室 + 企业实训站（dap-v2 两节点 K8S 集群）

- **企业站 PR 任务**：环境 onboard——开通集群只读账号、克隆课程仓库并切到 `course/L01-baseline` 分支，提交首个 PR（内容：本组《虚拟数据部成立申请表.md》），走通 PR 规范。
- **课后费曼任务**：向一位非技术亲友解释"什么是 Data Agent、它凭什么把取数从 2 天缩到 5 分钟"，录 1 分钟音频提交。

二、任务描述

某零售集团数据部收到业务部门联名委托：门店运营要一份"上月 GMV 排名"竟排队 2 天，月度经营会经常拿到过期数据。CIO 要求数据部两周内交付三件事：量化诊断"取数为什么慢"、演示 DAP-v2 Data Agent 自助查数能力（含 420ms FAQ 直答）、给出数据部自身的能力转型清单。

三、学习目标

1. 【记忆】能默写传统取数链路 5 个环节（业务提单→开发排期→手写 SQL→测试校验→发布交付）及各环节典型耗时，随堂小测正确率 ⩾80%。
2. 【记忆】能说出 DAP-v2 至少 5 项核心事实与指标：FAQ 直答 420ms（LLM 全链路 56s，约 130 倍）、held-out 24 题评测 91.7%（bootstrap CI 79.2–100）、k6 140RPS、105.9 万订单零售数仓、四层安全护栏、三级缓存。
3. 【理解】能用"取数排队 2 天"案例解释数据中台要解决的三个根本问题——口径不一致、链路太长、技能门槛高，并各举 1 个自己的例子。
4. 【理解】能按名称与顺序复述 NL2SQL 五步管线（Schema Linking→混合检索→LLM 生成 qwen2.5:14b→自校验→沙箱执行），并说出"为什么不能一步到位"的 2 条工程理由。
5. 【理解·素养】能陈述本组虚拟数据部三角色（数据工程/业务分析/质量治理）职责与轮值规则，并在课程公约（含"诚实报告缺陷"条款）上签名。

四、教学重点与难点

教学重点

1. 传统取数链路痛点与 Data Agent 破局点的一一对应：链路长→自然语言自助化；口径乱→知识引擎（CRDB 元数据 + Milvus 混合 RAG）；门槛高→NL 交互 + 四层护栏兜底。

2. DAP-v2 端到端能力地图的整体印象：React 控制台→GraphQL/REST 网关（FastAPI+Strawberry）→LangGraph 风格编排→洞察/质量/根因/ETL 四 Agent→知识引擎→MCP 工具层（sql-executor）→TiDB 零售数仓（细讲留待 L03）。

教学难点（附突破策略）

1. **NL2SQL 五步管线为什么不"一步到位"**——学生易把 LLM 当魔法，认为一句提示词即可。

突破策略：①"图书馆找书"类比：锁书架 = Schema Linking（105.9 万行、几十张表的搜索空间收敛）、翻索引卡 = 混合检索、写读书笔记 = LLM 生成、自查一遍 = 自校验（拦幻觉列名）、在阅览室试读 = 沙箱执行（只读 + LIMIT）；②现场拆一条真实查询的五步管线日志，逐步看耗时与中间产物。

2. **从"学生心态"到"虚拟数据部员工心态"的角色转换**。

突破策略：仪式感设计——颁发部门聘书、角色牌上墙、轮值表签字、课程公约集体签名；本讲起所有任务单以"部门"为单位提交并署角色名。

五、教学准备

类别	准备内容
环境	① DAP-v2 演示环境（只读）：React 控制台 `https://console.dap-v2.local`（Ingress TLS，每人账号 course-student-XX）；② TiDB 零售数仓只读账号 course_ro（10.167.2.176:4000）；③ 两节点 K8S 集群大屏投屏：10.167.2.175（master 16C/126G）+ 10.167.2.176（worker 64C/125G）
资料	课程手册、《DAP-v2 技术白皮书（教学版）》、20 张脱敏历史取数工单（含提单时间/交付时间/需求原文）、六步法挂图、《虚拟数据部章程》与角色卡、课程公约、痛点便签
分组	4~5 人/组 = 1 个"虚拟数据部"；角色轮值：数据工程/业务分析/质量治理 + 部门负责人（每周轮换，本讲竞聘产生首任负责人）
仓库	`git clone <课程仓库> && git checkout course/L01-baseline`；PR 目标分支 `course/L01-review`
安全须知	演示与数据库账号一律只读；工单材料已脱敏（门店/人名编码）；费曼录音须征得讲述对象同意

六、教学过程设计（六步法，校内 4 学时）

6.0 教学过程总表

步骤	时长	核心内容	主要产出
资讯	30′	取数工单墙阅读、痛点归	痛点便签墙

		纳；DAP-v2 生产大屏初见	
计划	30′	工单分类量化统计；制定本讲任务计划与分工	《痛点画像表》
决策	20′	各组选定 3 个"要向 CIO 演示"的验证场景	《演示验证清单》
实施	90′	①手工取数体验与痛点量化 ② NL 查数与 FAQ 直答对照实验 ③能力地图拼图 ④组建虚拟数据部	4 项任务单产物
检查	40′	组间按检查单互查 + 教师抽查关键指标复述	检查单得分
评价 + 学生讲堂	30′	"如果我是 CIO"讲堂、量表自评互评、教师总结	评价量表

6.1 资讯（30′）

- 【教师活动】投屏 3 封脱敏的业务方催单邮件与 20 张取数工单，抛出主问题："一份 GMV 排名为什么要等 2 天？"；带领学生到 K8S 大屏前看 dap-v2 生产命名空间的真实 Pod 列表，说明"破局工具已投产"。
- 【学生活动】阅读工单，每人写 2 张痛点便签（现象 + 猜测原因）贴上便签墙；按"等待久/口径吵/改不停"三类现场归堆。
- 【教学方法】工作坊研讨 + 实物（工单）教学法。
- 【设计意图】用真实业务材料制造认知冲突，激活先修课经验，痛点由学生自己"发现"而非教师告知。

工单墙预埋三条线索（教师提前布置，供归纳时"恰好"被发现）：①同一需求三次返工的连锁工单；②跨部门口径冲突工单（GMV 含不含退款）；③积压超 5 天的"幽灵工单"（提单人已离职）。

附：本讲术语速查表（随课程手册发放，资讯环节人手一份）

术语	一句话解释（今天达到这个理解水平即可）
数据中台	把"取数、算数、管口径"做成全公司共用的能力平台，而不是每个需求从零写 SQL
Data Agent	能听懂自然语言、替业务去数仓查数并解释结果的智能体
NL2SQL	把"上月各门店 GMV 排名"这类自然语言翻译成 SQL 的技术
FAQ 直答	高频标准问题走预先核准的答案库直接命中，420ms 级返回
混合检索 RAG	向量相似 + 关键词 + 精确匹配多路召回知识，供生成时参考
四层护栏	sqlglot 语法白名单 / 资源 LIMIT / 租户表授权 / 审批，

	层层拦危险 SQL
held-out 评测	藏起来不给系统"复习"的 24 道题，专测真实水平（91.7%）
语义缓存	问法不同但意思相同的问题直接复用答案（相似度阈值 0.92）

6.2 计划（30′）

- 【教师活动】发放《痛点画像表》模板与统计口径（耗时 = 交付时间−提单时间）；指导各组把 20 张工单按类型/耗时/返工次数分类统计，画出耗时分布条形图。
- 【学生活动】分工统计工单（业务分析角色主导），计算"平均排队时长、返工率、重复需求占比"三个数；数据工程角色列出每张工单涉及的表名（引出 ods_orders 等真实表）；质量治理角色记录口径冲突工单。
- 【教学方法】任务驱动 + 小组协作。
- 【设计意图】用数据量化痛点，训练"用数据说话"的职业习惯（HSA 诚实文化第一课）。

《痛点画像表》统计栏模板：

统计项	口径定义	本组结果
平均排队时长	交付时间−提单时间（工作日口径）	
返工率	有 ⩾1 次口径修改的工单占比	
重复需求占比	与近 90 天历史工单雷同的占比	
最慢环节	五环节中平均耗时最大者	

6.3 决策（20′）

- 【教师活动】提出决策任务："CIO 只给你 15 分钟演示，选哪 3 个场景最能证明 Data Agent 有效？"给出评审约束（必须覆盖：快、准、安全）。
- 【学生活动】各组讨论并锁定 3 个场景（预期方向：① FAQ 口径直答 420ms；② NL 查"上月各门店 GMV 排名前十"；③演示一条危险 SQL 被护栏拦截）；提交《演示验证清单》待教师确认可行性。
- 【教学方法】决策听证（教师逐组 3 分钟质询）。
- 【设计意图】在真实约束下做取舍，为实施环节的对照实验定靶。

候选演示场景池（教师供给，各组挑 3 并说明覆盖面）：

场景	证明点	风险提示
FAQ 口径直答（420ms）	快 + 口径统一	需确认问句在直答库覆盖范围内
NL 查门店 GMV 排名	准（直连数仓）	首次生成走全链路，耗时波动大
危险 SQL 被护栏拦截	安全	须用教学预置攻击语句，勿自造
同题两种问法同一结果	一致性	语义缓存未命中时对比不明显

6.4 实施（90’）

子步骤 1：手工取数体验与痛点量化（25’）

用 TiDB 只读账号亲手跑一次"传统取数"，体验技能门槛：

```
mysql -h 10.167.2.176 -P 4000 -u course_ro -p -e "SELECT COUNT(*) AS cnt FROM ods_orders;"
# 预期 cnt ≈ 1,059,000（105.9 万订单，这就是业务方要的"数"的原料）
```

再尝试口算"上月各门店 GMV 排名前十"需要哪些表、哪些关联、哪些过滤——记录所需 SQL 技能点清单；对照工单统计出"排队 2 天"的时间去向（排期约占 60%、写 SQL 与测试约占 40%）。

技能点清单示例（预期学生列出）：多表 JOIN、退款冲抵逻辑、门店归属维表关联、测试数据过滤、分页与导出——这正是"业务方不会、数据部排队"的技能门槛实证。

子步骤 2：NL 查数与 FAQ 直答对照实验（25’）

在 React 控制台完成两组对照，用秒表记录：

实验	操作	预期现象
A. FAQ 直答	问"GMV 的统计口径是什么？"	走直答链路，约 420ms 返回，界面标注直答来源
B. 强制 LLM 全链路	同一问题关闭直答开关	走完整生成链路，约 56s——对比出约 130 倍差距
C. NL 查数	问"2025 年 9 月各门店 GMV 排名前十"	打开管线日志，依次看到 Schema Linking→混合检索→LLM 生成→自校验→沙箱执行五步及各自耗时

学生填写《演示验证记录表》：每步的输入/输出截图或摘要、总耗时、生成 SQL 是否可读。

演示 C 的生成 SQL 样例（预期系统产出，供对照判读——注意它命中的是预汇总层）：

```
-- 预期命中 dws_store_daily_sales（门店×日已汇总），而不是在 ods_orders 上现算
SELECT store_id, SUM(gmv_amt) AS gmv
FROM dws_store_daily_sales
WHERE stat_date BETWEEN '2025-09-01' AND '2025-09-30'
GROUP BY store_id
ORDER BY gmv DESC
LIMIT 10;
```

《演示验证记录表》五步耗时栏（对照管线日志逐行填写）：

步骤	观察要点	本组实测
Schema Linking	命中了哪些候选表/列	
混合检索	召回了哪些知识片段	
LLM 生成	SQL 是否可读、引用表是否正确	
自校验	是否发生回炉重生成（次数）	
沙箱执行	行数、耗时、是否带 LIMIT	

子步骤 3：能力地图拼图（20’）

发放 8 张组件卡（React 控制台 / GraphQL 网关 FastAPI+Strawberry / LangGraph 风格编排 / 四 Agent / CRDB + Milvus + Nebula 知识引擎 / MCP sql-executor / TiDB 数仓 / Pulsar 异步）。各组按"一次提问的旅

程"把卡片排成端到端链路并推举 1 人用 2 分钟讲解；教师对照官方架构图纠偏（本讲只求"顺序正确＋一句话职责"，细节留 L03）。

子步骤 4：组建虚拟数据部（20′）

宣读《虚拟数据部章程》→ 竞聘首任部门负责人 → 认领角色卡（数据工程/业务分析/质量治理）→ 签署轮值表 → 全员在课程公约签名（重点条款：任务单不虚报、缺陷如实标注、每周角色轮换）。产出《虚拟数据部成立申请表.md》留作企业站首个 PR 内容。

6.5 检查（40′）

- 【教师活动】发放 8 项检查单（如：耗时分布图有数据支撑？FAQ 420ms 与 LLM 56s 两组秒表数都记录了？五步管线顺序默画正确？组件链路顺序正确？）。
- 【学生活动】组间两两互查打分；教师随机抽 3 组各 1 人复述"91.7%、140RPS、420ms"三个数字的含义，答错当场回炉 2 分钟微讲解。
- 【教学方法】清单检查＋随堂抽测。
- 【设计意图】当堂暴露理解偏差，重点防止"看完演示只记住神奇、没记住证据"。

8 项检查单（检查环节逐项打勾，缺一当堂回炉）

#	检查项	通过标准
1	耗时分布图	有工单数据支撑并标注样本量
2	三个量化数字	平均排队时长/返工率/重复需求占比可复算
3	时间去向归因	能说出排队 2 天的主要去向及占比
4	对照实验 A/B	420ms 与 56s 两个秒表数都有记录
5	五步管线顺序	默画顺序正确且各配一句话作用
6	能力地图顺序	8 张组件卡链路与官方架构一致
7	指标复述抽查	91.7%/140RPS 含义口头答对
8	虚拟数据部四件套	聘书/角色卡/轮值表/公约签名齐全

6.6 评价＋学生讲堂（30′）

- 【教师活动】主持"如果我是 CIO"讲堂（抽 2 组各 5 分钟：会不会采购 Data Agent？依据是什么？）；组织量表自评互评；总结本讲并布置企业站任务与费曼任务。
- 【学生活动】讲堂发言（脱稿、必须引用本组实测数字）；完成自评互评；记录回炉点。
- 【教学方法】费曼讲台＋量表评价。
- 【设计意图】以教代学检验"理解"层级是否达成；数字引用强制把记忆目标落地。

教师收束三句话（评价环节末尾必讲）：①今天你们看到的所有数字都来自可复现实验，这门课的规矩是"无证据不下结论"；② Data Agent 不是替代数据工程师，而是把重复取数换成治理与判断；③从下周起你们就是"数据部"，考核从考勤变成交付。

七、企业站实践任务卡（2 学时）

项目	内容
任务目标	完成课程环境 onboard 并走通一次标准 PR 流程
操作步骤	① 领取集群只读 kubeconfig（企业导师现场发，仅可 get/describe/logs，namespace：dap-v2）；② `kubectl get pods -n dap-v2 -o wide` 记录各组件 Pod 与所在节点；③ `git clone <课程仓库> && git checkout -b g01/L01-onboard`（基于 course/L01-baseline）；④ 提交本组《虚拟数据部成立申请表.md》至 `docs/04-学员工坊/g01/`；⑤ 推分支并发 PR 至 course/L01-review，按模板填写自查项
交付物	PR 链接 + 《onboard 记录单》（含 Pod 清单截图、组员账号清单、角色分配）
评审标准	PR 命名/目录/模板合规（3 分）；文件内容完整含角色表（3 分）；Pod 清单真实可见 dap-v2 命名空间（2 分）；自查项如实勾选（2 分）

双导师签栏	签名	日期
企业导师		
校内导师		

PR 描述模板必填字段：组号与角色分工 / 改动摘要（≤3 行）/ 自查清单（文件路径正确、无个人隐私、无真实凭据）/ 验证方式（如何证明文件落在正确位置）。

八、评价设计（任务单评分表）

评价维度	权重	评分标准（满分按权重折算）
痛点诊断报告	25	优(22–25)：三个量化数字准确、时间去向有归因；良(18–21)：数字齐全归因浅；中(12–17)：仅罗列现象；差(<12)：无数据支撑
演示验证记录	25	优：A/B/C 三实验都有秒表数 + 五步日志摘要；良：缺 1 项；中：只有截图无数值；差：未做对照
能力地图拼图	20	优：8 卡顺序全对 + 每卡一句话职责准确；良：顺序对职责含糊；中：≤2 处顺序错；差：链路断裂
虚拟数据部组建	15	聘书/角色卡/轮值表/公约签名四件套齐全；缺 1 项扣 4 分
学生讲堂表达	15	优：脱稿 + 引用 ≥2 个实测数字；

		良：念稿但数字对；中：无数字；差：未发言

过程性观察点（教师随堂记录，不计分但作为"理解"层级佐证）：①便签墙是否出现"口径/排队/门槛"之外的自发洞察；②对照实验中是否主动追问"56s 花在哪一步"；③公约签名环节是否有学生质疑条款（视为高阶参与）。

折算说明：五维度得分相加即任务单百分制分；缺勤补做按 80% 计；互查放水（检查单全勾但教师抽查不过）该检查员所在维度减半——课程公约诚信条款适用。

九、课后费曼任务

项目	内容
讲给谁	一位非技术亲友（父母/室友/文科同学）
讲什么	"以前公司取个数要等 2 天，现在有个叫 Data Agent 的东西 5 分钟搞定——它是怎么做到的？"必须覆盖：排队 2 天的原因（3 选 1 即可）；Agent 至少 1 个真实数字（420ms/91.7%/105.9 万任选）；一句话说明"它不碰危险 SQL"（护栏）
自评三问	① 我能全程不用术语讲清吗？② 我在哪里卡壳了（记录原话）？③ 卡壳处对应回炉哪个知识点（取数链路/NL2SQL 五步/FAQ 直答/护栏——回炉资料：课程手册第 1 章 + 本讲任务单）？

讲述提纲提示（三段式）：先讲"排队 2 天"的具体样子（一个等待场景）→ 再讲"5 分钟"是怎么发生的（五步管线中任选 2 步）→ 最后讲"我为什么敢信它"（护栏 + 评测数字）。

十、教学反思栏（授课后填写）

反思维度	记录
目标达成分度（5 个目标逐条：超额/达成/部分/未达）	
学生卡点（环节/人数/具体表现）	
时间偏差（六步实际用时 vs 计划）	
材料与改进（工单/类比/实验哪里要改）	
需在后续讲次回炉的知识点	
优秀表现 / 学生金句记录	
需个别辅导学生与安排	