实验 L10：LLM 降级路径设计与混沌验证

（实验指导 | 对应学习情境 L10 | 企业站 2 学时 | 实验⑩）

项	内容
实验类型	探究性（故障注入）
实验环境	课程环境 LiteLLM 网关、Redis（教师授权注入点）
分组	结对 + 部门联测
提交物	降级矩阵验证报告（三级各 1 次）+ 成本对照表

一、实验目标

1. 【分析】验证降级矩阵：主模型→备模型→确定性模板（DPC）的触发条件与行为差异。
2. 【评价】验证三级缓存（L1 进程内/L2 Redis/L3 语义缓存）命中链与降级的组合行为。
3. 【素养】体会"降级不是失败，是把失败变成可预期"（DPC 铁律）。

二、环境与准备

- 注入手段（教师授权）：断 Redis 连接、修改主模型端点为无效地址（均在课程命名空间内）。
- 安全边界：**只允许对课程命名空间注入**；对生产命名空间的任何操作 = 安全红线（EVAL-02 §三）。
- 计分表准备：记录每次调用的 model 标记、时延、是否命中缓存。

三、实验步骤

步骤 1：基线与缓存命中链（30′）

同一问句连续调用 4 次，记录：

调用次	L1	L2	L3	实际路径	时延
1	miss	miss	miss	全链路	
2					
3					
4					

✓ 验证点：命中层级随调用次数变化可解释（先 L1 后 L2/L3）。

步骤 2：主模型故障注入（30′）

1. 将主模型端点置为无效 → 发起查询。
2. 记录：是否自动切换备模型？备模型响应质量差异（同一问句对比两次 SQL）。
3. 再把备模型也置无效 → 应落 DPC 确定性模板（返回受控话术/拒绝而非瞎编）。

✓ 验证点：三级降级各 1 次日志截图；恢复主模型后验证回落正常。

步骤 3：Redis 故障注入（30'）

1. 断 Redis → 观察缓存层降级行为（穿透到 LLM 还是快速失败？）。
2. 恢复 Redis → 验证缓存重新生效。
3. 对照 dap-v2 生产约定：这类混沌场景在上线前必须验证（发布检查单之一）。

步骤 4：成本对照表（10'）

路径	时延	估算相对成本	适用场景
FAQ 直答	~420ms	≈0（零推理）	精确命中
LLM 全链路	~56s	高	新问句
语义缓存命中	<1s	低	高频相似问

四、常见坑与排障

现象	原因与处置
注入后一直挂起不降级	超时配置缺失；检查重试/超时参数（生产用 `curl -m` 的经验同理）
恢复后仍走备模型	熔断器半开窗口未过；等窗口或重启验证
降级到 DPC 返回"暂不支持"被判失败	判断标准错了——受控拒绝优于幻觉 SQL

五、提交物与验收标准

提交物	验收标准
降级矩阵报告	三级各 1 次 + 回落验证，日志截图
缓存命中表	4 次调用记录完整
成本对照表	三行齐全，数值来自本组实测

六、诚实清单（提交前必填）

未验证/未完成事项	原因	计划补救