学习情境 L15：测试金字塔与性能验证（6 学时）

对应《授课计划总表》第 15 周｜学习领域 LF6｜布鲁姆主层级：评价

*前置：L14（护栏单测）；本讲回答一个问题——**凭什么敢上线？**用 67 个单测、7 条 E2E、一份 k6 报告和一套评测方法学组成"证据链"。*

一、学习情境基本信息

项目	内容
学习领域	LF6 测试、性能验证与发布运维（评价）
讲次	第 15 讲（第 15 周）
学时	6 学时 = 校内理实一体 4 学时（六步法）+ 企业实训站 2 学时（PR 实战）
布鲁姆主层级	评价（Evaluate）
双元场地	校内：理实一体教室（课程 ns：pytest/Playwright/k6 全套环境）；企业站：dap-v2 课程分支（tests/ 目录 + reports/）
企业站 PR 任务	为自己本学期的改动补 2 个单测并过覆盖率门禁（行覆盖⩾80%，当前基线 87%/67 测）
课后费曼任务	学生讲堂⑥预演：向同学讲一份 k6 压测报告（p95/错误率/拐点三要素）

二、任务描述

客户委托单（平台运营部）

大促前运营部要一份"能不能扛住"的证明：请提交测试证据链——单测与覆盖率报告、无头端到端全链路结果、k6 阶梯压测拐点判读（300VU/26865 请求/峰值 140RPS/错误率 2.4% 的实测数据要能被解释）、NL2SQL 评测集置信区间说明，并演示一次 Redis 故障下的降级自愈。结论需一页纸可核验。

三、学习目标

1. 【理解】画出本项目测试金字塔（单元 67 → 契约/护栏 → E2E 7 → 压测/评测）并说明各层职责、数量配比与执行成本的反比关系。
2. 【应用】运行 pytest + 覆盖率门禁与 Playwright 无头 E2E，从报告定位失败用例所属层与修复责任。
3. 【分析】判读 k6 阶梯压测报告：p95 延迟、错误率 2.4% 的构成、RPS 拐点档位，并写出一句瓶颈结论。
4. 【评价】用统计视角评判评测证据：论证"12 题 100% 为何没有统计意义"，说明 24 题 + held-out 12 + bootstrap 95% CI 的必要性。

5. 【评价】论证覆盖率门禁为何设 80%（项目实测 87%）：过高（凑数测试）与过低（回归裸奔）的代价权衡。

四、教学重点与难点

教学重点

1. 测试金字塔的成本—反馈结构：底层数量多跑得快（毫秒级）、顶层数量少贴近真实（分钟级），66+→7→1 的配比不是随意的。

2. k6 报告三要素判读法：p95（尾延迟比均值诚实）、错误率（2.4% 是谁的错——超时还是断言）、拐点（RPS 不再随 VU 增长的台阶）。

教学难点

1. **"12 题 100% 为何无统计意义"的统计直觉**——学生直觉是"全对还不说明问题？"

- 突破策略：现场算概率——真实准确率 0.85 时 12/12 的概率约 14%，0.70 时仍有约 1.4%；再演示 bootstrap 重采样让置信区间"长出来"，直觉冲突被数据化解（教授方法学的通俗版）。

2. **覆盖率门禁的度**——为什么是 80 不是 100 也不是 50。

- 突破策略：两个反例对照——100% 门禁催生"为覆盖而测"（断言空洞），50% 门禁下 L14 那类护栏函数可能整段裸奔；用"护栏模块必须 80+、胶水代码可豁免"的分级门禁收束讨论。

五、教学准备

类别	内容
环境	课程 ns：dap-gateway（注入了 L10 降级矩阵）、pytest + coverage、Playwright（无头）、k6、混沌回放脚本（Redis 故障注入时间线日志）
资料	k6 实测报告（300VU/26865 req/140RPS/err 2.4%）原始 JSON、评测集（24 题，held-out 12）与 bootstrap 脚本、test_bindings.py 源码、覆盖率报告样例
分组	2 人一组；讲堂环节每组预讲 3 分钟"我的 k6 三要素"

六、教学过程设计

第 1 步：资讯（30 分钟）

【教师活动】 白板画塔：单元 67（含 test_bindings 占位符绑定防线）→ 契约/护栏（L14 恶意单测归宿）→ E2E 7 条（Playwright 无头全链路）→ 压测与评测（k6 阶梯、24 题评测）；给出实测数字 67/7/300VU/2.4%，提问"如果只能保留一层，丢哪层最疼？"。

【学生活动】 对照 dap-v2 的 tests/ 目录数一数各层文件数与金字塔是否吻合；把本学期自己提交过的 PR 归类到塔的某一层并贴名签。

【教学方法】 图示讲解 + 目录考古。

【设计意图】 用学生自己的提交史锚定金字塔——"我的改动在哪一层被保护"比抽象分层更有代入感；丢层思想实验为后面门禁讨论埋线。

第 2 步：计划（30 分钟）

【教师活动】 发布"证据链任务单"：四站（单测覆盖率站/E2E 站/k6 判读站/评测统计站）各须产出一条可核验结论；给出 k6 判读三问模板与统计站实验步骤。

【学生活动】 排定小组四站的顺序与分工（建议底→顶顺序）；预填 k6 三问（p95 是多少/错误率构成/拐点在第几档 VU）的"预判值"；圈出自己本学期改动对应的单测缺口（为企业站 PR 备料）。

【教学方法】 站点式学习计划 + 预测—验证。

【设计意图】 预填预判值延续 L14 的认知冲突法；提前圈单测缺口让企业站 PR 有明确靶子，避免"随便补两个测"。

第 3 步：决策（20 分钟）

【教师活动】 逐组确认：补测对象选哪个函数（优先护栏/绑定/缓存等共享模块，符合 TCG"共享包必测"）、预计覆盖增量；裁决争议（如"我的改动是 yaml，测什么？"→引导为"部署变更的冒烟脚本断言"）。

【学生活动】 定稿补测清单（2 个单测的目标函数与断言草案）；在任务单登记选择理由。

【教学方法】 决策谈话。

【设计意图】 "yaml 改动测什么"是真实工程问题，公开裁决一次，全班受益；补测对象决策本身就是评价层级行为（判断什么值得测）。

第 4 步：实施（90 分钟）

4.1 金字塔底座：单测＋覆盖率门禁（约 20 分钟）

```
pytest tests/ -q --cov=app --cov-report=term-missing --cov-fail-under=80
# 门禁 80%（TCG 铁律：共享包≥80、护栏/缓存等关键模块≥80）
# dap-v2 当前基线：67 测全绿，行覆盖 87%

pytest tests/test_bindings.py -q   # 占位符绑定防线：参数必须走绑定而非拼接
```

读报告两个动作：① 找出 `Missing` 列里最长的连续行段（最值得补的缺口）；② 区分"没测到的逻辑"与"测了但断言空洞"（后者更危险）。

4.2 中层：E2E 7 条与冒烟 9 项（约 15 分钟）

```
npx playwright test e2e/ --reporter=line   # 7 条无头全链路（登录→提问→出数→图表）
make smoke                                 # 9 项冒烟（健康/查数/直答/备份产物…）
```

判读：E2E 失败先问"哪一层背锅"——E2E 红而单测绿 = 集成缝隙（环境/契约），两层都红 = 逻辑缺陷；记录一条失败归因（若全绿，回放教师预置的失败视频）。

4.3 顶层之一：k6 阶梯压测报告判读（约 25 分钟）

```
k6 run loadtest/staircase.js --summary-export=reports/k6-staircase.json
# 上一次全量实测：300VU 阶梯、26865 请求、峰值 ~140RPS、错误率 2.4%
```

三问判读（任务单必填）：

1. **p95 是多少？** 尾延迟代表最差的 5% 用户体验，比均值诚实；对照 SLA（如 p95<800ms）。

2. **错误率 2.4% 是谁的错？** 拆解构成：超时（资源层 L2 的 20s 掐断/连接池排队）还是断言失败；2.4%≠灾难，但要能说清来源。

3. **拐点在第几档 VU？** RPS 不再随 VU 增长、p95 陡增的台阶即容量拐点；140RPS 前后的那档就是单副本的诚实容量（呼应 L6 容量外推公式）。

产出：在报告 JSON 上圈出拐点档位，写一句瓶颈结论（如"缓存命中率下降后 DB 直查比例上升，p95 陡增"）。

4.4 顶层之二：评测集方法学＋混沌回放（约 30 分钟）

（a）"12 题 100%"的统计脆弱性（教授方法学的通俗版）：

```
# 若真实准确率 p=0.85，12 题全对的概率：
0.85 ** 12   # ≈ 0.142 —— 真实水平 85% 的系统有 14% 概率"看起来全对"
0.70 ** 12   # ≈ 0.014 —— 连 70% 的系统也可能偶发 12/12
# 结论：12/12 区分不了 0.70 与 0.85，"100%"不是证据
```

升级方案三件套：**24 题**（样本翻倍）＋**held-out 12**（评测题绝不进 few_shots/知识库，防背题）＋**bootstrap 95% CI**：

```
python scripts/eval_nl2sql.py --set heldout12 --bootstrap 10000
# 输出：acc=0.875，bootstrap 95% CI [0.71，0.96]
# 报告口径：必须带区间，"87.5%"单独出现即不诚实
```

（b）混沌降级回放（Redis 故障注入时间线）：

```
T+0    注入：课程环境断开 dap-cache 连接（故障注入脚本）
T+2s   主链直穿：/api/nl2sql 仍返回 200，响应头 degraded:true、cache_hit:false
T+8s   p95 短暂抬升（全部流量落到 DB）——对照 4.3 的拐点解释
T+90s  Redis 恢复 → 缓存命中回升、degraded 消失（自愈回归）
```

契约要求（DPC 铁律）：**每条降级路径必须有测试证明它会被触发且行为正确**——混沌回放就是那条测试的现场版；"降级没崩"和"降级被测过"是两回事。

第 5 步：检查（40 分钟）

【教师活动】 组织"证据链互审"：相邻组交换四站结论，逐条核对是否"可核验"（有命令、有数字、有出处）；抽查 2 组重跑对方的 k6 判读与 bootstrap 数字。

【学生活动】 互审打勾/打叉：p95 有没有写具体毫秒？错误率有没有拆构成？拐点有没有指认档位？评测结论有没有带置信区间？覆盖率结论有没有区分"没测"与"空测"？修补被打叉项。

【教学方法】 同伴互审＋证据核查。

【设计意图】 "可核验"是 L16 发布决策的前置训练——不可核验的结论在门禁评审会上等于没有；互审清单直接复用 HSA（诚实自评）文化的操作化标准。

第 6 步：评价＋学生讲堂（30 分钟）

【教师活动】 主持学生讲堂⑥：抽 2 组各 5 分钟讲一份 k6 报告（三要素齐全为及格线）；10 分钟总结证据链全景并抛出 L16 引子——"证据齐了，谁有权按下上线按钮？"；布置费曼任务与岗位视角（测试开发工程师的一天）。

【学生活动】 讲堂主讲 + 同伴按"三要素/一句话结论/诚实度"互评；每人写一句"我今天修正的一个直觉"（如"全对≠正确""均值会骗人"）投入反馈箱。

【教学方法】 费曼讲堂 + 概念变更自述。

【设计意图】 统计直觉的修正是本讲最难的认知成果，用"修正了什么直觉"显性化；讲堂与 L16 答辩的"讲证据"能力同构，提前彩排。

七、企业站实践任务卡（2 学时）

栏目	内容
任务目标	为自己本学期的改动补 2 个单测，PR 通过覆盖率门禁（⩾80% 且不低于当前基线 87%）
步骤	① 定位本学期改动的目标函数（决策环节已圈定）② 写用例：断言具体行为（禁"调用不报错"式空测）③ `pytest --cov` 本地验证增量 ④ 提 PR，描述注明：改动来源（哪次 PR）→测试了什么行为→覆盖率前后对比
交付物	① PR：2 个单测 ② 覆盖率前后对比截图（如 87%→88%）③ PR 描述中的断言说明（每个用例断言了什么行为）
评审标准	断言具体（空测按配而未接记 fail）；目标是共享/关键模块优先；覆盖率不低于基线；描述如实（未验证的路径写明未验证）
企业导师签字	_ _ _ _ _ _（pass/fail + 一句话）
校内导师签字	_ _ _ _ _ _（pass/fail + 一句话）

八、评价设计（任务单评分表）

维度	权重	评分标准（优 90+/良 75+/中 60+/差 <60）
金字塔结构与归因	15%	能画塔并把自己的改动归层；E2E 红/单测绿的归因正确
覆盖率判读	15%	区分"没测"与"空测"；能指出最值得补的缺口行段
k6 三要素判读	25%	p95/错误率构成/拐点档位齐全，瓶颈结论一句话成立
评测统计论证	25%	能算出 12/12 的误导概率；解释 held-out 与 CI 的作用；结论带区间
混沌回放与 DPC 理解	10%	能指认降级路径与其契约测试的对应关系
补测 PR（企业站）	10%	2 用例断言具体、覆盖率达标、描

		述如实

九、课后费曼任务

- **讲给谁**：同学或家人（扮演"不懂技术的运营总监"最佳）。
- **讲什么**：讲一份 k6 报告——① p95 是什么、为什么比平均值更该看（举"9 个人 1 秒+1 个人 100 秒"的例子）；② 错误率 2.4% 意味着什么、要怎么追问构成；③ 拐点为什么是"诚实容量"（连回 L6 的外推公式）。
- **自评三问**：① 对方听完后能复述"为什么平均值会骗人"吗？② 我有没有只报好数字、回避错误率构成？③ 如果对方追问"那 2.4% 能上线吗"，我能回答"要看构成与 SLA"而不是拍脑袋吗？

十、教学反思栏

反思维度	记录（留白）
目标达成（统计直觉是否被修正）	
k6 三站耗时与判读质量	
学生补测 PR 的空测比例	
混沌回放的环境稳定性	
与 L16 发布门禁的证据衔接	